



UNIVERSIDADE D
COIMBRA

Relatório Projeto ECAC

Classificação de Atividades Humanas

Data: 07/12/2025

Turma: PL7 | ECAC | LEI

Docente: Professor Marco Simões

Alunos: Francisco Santos | 2023215501 | Gonalo Silva | 2023215512

Índice

I. Meta 1

1. Introdução

1.1. Contextualização

1.2. Objetivos da Meta 1

1.3. *Dataset* e Metodologia

2. Análise e Tratamento de *Outliers*

2.1. Análise Exploratória com *Boxplots*

2.2. Detecção de *Outliers* com *Z-Score*

2.3. Detecção Multivariada por *Clustering*

3. Engenharia e Seleção de Características

3.1. Análise de Significância Estatística

3.2. Extração de Características

3.3. Redução de Dimensionalidade com PCA

3.4. Seleção de Características com *Fisher Score* e *ReliefF*

4. Conclusão da Meta 1

II. Meta 2

5. Introdução à Meta 2: Aprendizagem e Generalização

6. Estratégias de Data Augmentation

6.1. Análise de Desequilíbrio de Classes

6.2. Implementação Robusta do SMOTE

7. Análise de *Features* e Estratégias de Validação

7.1. *Handcrafted Features* vs. *Embeddings*

7.2. *Within-Subject* vs. *Between-Subject*

8. Classificação e Discussão dos Resultados

8.1. Otimização do k-NN

8.2. Limitações Físicas: O Problema da Fala

8.3. Tentativas Experimentais Falhadas

9. *Deployment* e Contexto de Aplicação

9.1. Limitações Físicas: O Problema da Fala

9.2. Seleção do Modelo e Justificação Estatística

9.3. Simulação da Pipeline de Produção

9.3.1. Seleção e Perturbação do Input

9.3.2. Estratégia de Treino e Inferência

10. Conclusão Final

1. Introdução

1.1. Contextualização

O reconhecimento de atividades físicas humanas (*Human Activity Recognition*) é um campo de estudo com importância crescente, impulsionado por aplicações em áreas como a saúde, o bem-estar e o desporto. A capacidade de monitorizar e classificar automaticamente as atividades que um indivíduo realiza permite o desenvolvimento de sistemas de assistência médica, monitorização de pacientes ou otimização de planos de treino.

Este projeto foca-se num problema de classificação supervisionada, utilizando dados de sensores inerciais para distinguir entre diferentes atividades.

1.2. Objetivos da Meta 1

O objetivo central desta primeira meta do trabalho prático é exercitar os conceitos fundamentais de uma *pipeline* de análise de dados. Esta *pipeline* abrange as fases críticas que transformam dados brutos em informação útil e otimizada para algoritmos de aprendizagem computacional.

As fases abordadas incluem:

- A preparação e limpeza dos dados.
- A identificação e tratamento de *outliers* (valores anómalos).
- A extração de características (*features*) descritivas.
- A seleção e redução de dimensionalidade do espaço de características.

1.3. Dataset e Metodologia

Para este estudo, foi utilizado o *dataset* FORTH-TRACE. Este *benchmark* é composto por dados adquiridos de 15 participantes, que realizaram um protocolo de 16 atividades distintas.

Os dados foram recolhidos por 5 dispositivos sensores, localizados no peito, pulsos e pernas, registando aceleração, velocidade angular (giroscópio) e variação do campo magnético (magnetómetro).

A metodologia desta meta consistiu em implementar um conjunto de rotinas em *Python* (conforme Ex. 1 e 2) para carregar e processar estes dados, seguindo os exercícios propostos no enunciado.

2. Análise e Tratamento de *Outliers*

O objetivo deste módulo foi identificar e analisar a presença de *outliers* no *dataset*. Para uniformizar a análise, e como passo de pré-processamento, foram calculados os módulos de cada vetor de sensor (acelerómetro, giroscópio e magnetómetro), conforme a fórmula apresentada no enunciado.


2.1. Análise Exploratória com *Boxplots*


Foi realizada uma análise univariada usando o método IQR (*Interquartile Range*), conforme a definição de *Tukey*, para analisar a densidade de *outliers*. Esta análise (Ex. 3.2) focou-se nos sensores do pulso direito.

Os resultados, visualizados através de *boxplots* (Ex. 3.1), mostram padrões claros:

- **Atividades Estáticas:** Atividades como "Stand" (1) e "Sit" (2) apresentam baixa densidade de *outliers*, indicando movimentos consistentes e regulares.
- **Atividades de Transição:** Atividades como "Stand->Sit" (8) ou "Sit->Stand" (9) apresentam uma densidade de *outliers* significativamente superior.

Esta observação é esperada, pois as transições são movimentos inerentemente mais bruscos e irregulares, gerando valores que fogem à distribuição normal da atividade.









2.2. Detecção de Outliers com Z-Score

Numa segunda abordagem (Ex. 3.3, 3.4), foi implementado o método *Z-Score* para identificar *outliers*. Este método classifica como *outlier* qualquer ponto que se desvie da média em mais de k desvios-padrão. Foram testados $k=3$, $k=4$ e $k=5$.

A comparação dos métodos (Ex. 3.5) para os sensores do pulso direito revelou:

- O **Z-Score com $k=3$** é o mais sensível, detetando mais *outliers* que o método IQR.
- O **Z-Score com $k=4$** é o mais conservador, detetando menos *outliers* que o IQR.
- O **método IQR** demonstrou ser mais robusto, pois não assume uma distribuição normal dos dados, sendo preferível para dados não-normais, como é o caso de muitas destas atividades.







2.3. Deteção Multivariada por *Clustering*


Finalmente, foram exploradas técnicas multivariadas para detetar *outliers*, considerando o espaço 3D dos módulos (Acelerómetro, Giroscópio, Magnetómetro).

- **K-Means (Ex. 3.6, 3.7):** O algoritmo K-Means foi implementado e aplicado com $k=3, 5, 7$. Nesta abordagem, os *outliers* são identificados como os pontos que apresentam as maiores distâncias aos centroides dos seus *clusters*. Esta técnica permite uma perspetiva multivariada, contrastando com a análise univariada do Z-Score. Foram também criados gráficos sem *outliers*, e aproximados, de forma a observar melhor os clusters.



Gráficos dos clusters formados pelo algoritmo K-Means ($k=5$)

- **DBSCAN (Ex. 3.7.1):** Como bônus, foi aplicado o algoritmo DBSCAN. Sendo um método baseado em densidade, o DBSCAN identifica automaticamente pontos em regiões de baixa densidade como "ruído" (*noise*), tratando-os efetivamente como *outliers*.



Gráficos dos clusters formados pelo algoritmo DBSCAN

3. Engenharia e Seleção de Características

Este módulo teve como objetivo comprimir o espaço do problema, extraindo e selecionando um conjunto de características (*features*) discriminantes.

3.1. Análise de Significância Estatística

O primeiro passo foi validar estatisticamente se os módulos dos sensores (utilizados na análise de *outliers*) eram, de facto, bons discriminadores entre as diferentes atividades.

Para tal (Ex. 4.1), foi primeiro aplicado o teste de normalidade de Kolmogorov-Smirnov, que revelou que a maioria das distribuições não segue uma distribuição normal. Consequentemente, foi utilizado o teste não-paramétrico de Kruskal-Wallis para comparar as médias entre as atividades.

Os resultados foram claros: para os três módulos de sensores, os *p-values* obtidos foram < 0.001 , indicando que as médias diferem de forma altamente significativa entre as atividades. Esta análise valida que os módulos dos sensores possuem um elevado poder discriminante e são *features* valiosas para a classificação.

3.2. Extração de Características Temporais e Espectrais

Seguindo a metodologia do Ex. 4.2, os dados foram segmentados usando janelas deslizantes (*sliding windows*) de 5 segundos, com uma sobreposição (*overlap*) de 50%. Segmentos que cobriam mais do que uma atividade foram descartados.

Inicialmente, foi tomada a decisão técnica de extrair características **apenas dos módulos** dos sensores, em vez de o fazer para cada um dos 9 eixos (x, y, z de cada sensor). No entanto, rapidamente percebemos a utilidade dos eixos tridimensionais – as atividades são medidas de forma diferente, consoante o tipo de movimento (por exemplo, a aceleração na atividade *Walk* será muito mais elevada no eixo x, enquanto que a atividade *Climb Stairs* terá maiores valores no eixo y).

Esta decisão criou um espaço de *features* de 162 (18 *features* x 9 eixos). Adicionando as 12 *features* multi-sensor (como SMA, AAE, etc.), obteve-se um *dataset* final com **174 características** por janela. O processo resultou num *dataset* limpo com 27.845 janelas válidas.


3.3. Redução de Dimensionalidade com PCA

A Análise de Componentes Principais (PCA) foi implementada (Ex. 4.3) como técnica de redução de dimensionalidade. O PCA transforma o espaço de *features* num novo espaço ortogonal, onde os componentes são ordenados por variância explicada.

Antes de aplicar o PCA, as 174 *features* foram normalizadas usando o Z-Score (Ex. 4.4). A análise da variância explicada (Ex. 4.4) respondeu à questão central: "Quantas dimensões são necessárias para explicar 75% do *feature set*?".

O resultado foi que são necessários apenas **14 componentes principais** para explicar **75.05%** da variância total. Isto representa uma compressão de 92% (de 174 para 14 *features*). O primeiro componente principal, sozinho, explica 37.8% da variância.

- **Vantagens (Ex. 4.4.2):** Redução drástica da dimensionalidade (13x mais rápido), combate ao *overfitting* e remoção de multicolinearidade.
- **Limitações (Ex. 4.4.2):** Perda de 22% da informação e perda de interpretabilidade, dado que os novos componentes são combinações lineares de todas as *features* originais.



3.4. Seleção de Características com Fisher Score e ReliefF

Como alternativa ao PCA, foram implementados (Ex. 4.5) dois métodos de seleção de características (*feature selection*) supervisionados: *Fisher Score* e *ReliefF*. Ao contrário do PCA, estes métodos não transformam *features*, mas antes classificam as 174 *features* originais, permitindo selecionar as mais importantes.

- **Fisher Score:** É um método estatístico, global, que avalia as *features* com base na razão entre a variabilidade inter-classe (boa) e a variabilidade intra-classe (má).
- **ReliefF:** É um método local, baseado em instâncias. Avalia as *features* pela sua capacidade de distinguir uma instância dos seus vizinhos mais próximos de classes diferentes (*misses*) e de a aproximar dos vizinhos da mesma classe (*hits*).

A análise comparativa (Ex. 4.6) das 10 melhores *features* de cada método revelou que estes são complementares:

- O Fisher Score (global, paramétrico) prioriza *features* com médias estatisticamente distintas.
- O ReliefF (local, não-paramétrico) é robusto a *outliers* e captura relações locais que o Fisher pode ignorar.

A união das *features* de topo de ambos os métodos (resultando em aprox. 16 *features* únicas) constitui um subconjunto robusto.

- **Vantagens (Ex. 4.6.2):** Mantém a interpretabilidade (sabemos que *feature* é importante, ex: *gyro_y_rms*), reduz *overfitting* e a complexidade computacional (compressão de 78% a 85%).
- **Limitações (Ex. 4.6.2):** Há perda de informação (*features* descartadas) e os métodos têm pressupostos (Fisher assume normalidade, ReliefF é sensível ao *k* e à amostragem).

4. Conclusão da Meta 1

A Meta 1 deste trabalho prático foi concluída com sucesso. Foi implementada uma *pipeline* completa de pré-processamento e engenharia de características para o *dataset* FORTH-TRACE.

A análise de *outliers* permitiu identificar as limitações de métodos como o Z-Score e a robustez do IQR e de métodos de *clustering*.

A decisão de extrair 174 características com base nos eixos dos sensores, em vez dos módulos, provou ser altamente eficaz, criando um *dataset* com mais significância estatística.

Finalmente, foram validadas duas estratégias de compressão:

1. **PCA:** Redução de 174 para 14 componentes, explicando 75.05% da variância (compressão de 92%).
2. **Feature Selection:** Redução de 174 para um subconjunto de ~16 *features* (união do Fisher/ReliefF), mantendo as mais discriminantes e a interpretabilidade (compressão de 78%).

O *dataset* resultante está limpo, otimizado e pronto para a próxima fase do projeto: a implementação e avaliação de modelos de *Machine Learning* para a classificação das atividades humanas.

5. Introdução à Meta 2: Aprendizagem e Generalização

Após a conclusão da Meta 1, onde o esforço incidiu na pré-processamento e engenharia de características (*Feature Engineering*), a Meta 2 orienta-se para a aplicação, otimização e validação rigorosa de modelos de classificação. O projeto, assim, estabelece como prioridade não apenas a obtenção de um modelo funcional, mas a comparação crítica entre diferentes paradigmas de representação de dados e estratégias de treino.

Nesta etapa, o projeto focou-se em três pilares fundamentais definidos no caderno de encargos:

1. Mitigação do Desequilíbrio de Classes: Reconhecendo que a recolha de dados em ambiente real produz amostras desproporcionais, a abordagem exigiu a implementação de técnicas de *Data Augmentation* (especificamente SMOTE) para garantir que o classificador não fosse enviesado pela frequência das atividades mais comuns.

2. Confronto de Paradigmas (*Features* vs. *Embeddings*): O trabalho propôs avaliar se as características estatísticas extraídas manualmente (conhecimento de domínio) superam ou não os *Embeddings* gerados automaticamente por modelos de *Deep Learning* (*Transfer Learning*), testando a eficácia de cada representação no reconhecimento das atividades 1 a 7.

3. Robustez da Validação e *Deployment*: Para além do treino do modelo (k-NN), o foco deslocou-se para a validade estatística dos resultados (testes de hipótese) e para a simulação de um cenário de produção (*Deployment*), onde a capacidade de generalização e a eficiência da pipeline completa são postas à prova.

Esta fase marca, portanto, a transição da análise exploratória para a construção de um sistema de decisão inteligente, fundamentado em métricas de avaliação sólidas.

6. Estratégias de *Data Augmentation*


6.1. Análise do Desequilíbrio de Classes

A análise preliminar do conjunto de dados revelou um desequilíbrio severo (*Ratio* de 3.31). Atividades estáticas como *Sitting* (Ativ. 1) dominavam a amostra, enquanto atividades combinadas como *Upstairs & Talking* (Ativ. 7) eram escassas.

Num classificador baseado em distância, como o k-NN, este desequilíbrio provoca um enviesamento da fronteira de decisão em direção à classe maioritária. O modelo tende a ignorar as classes raras para minimizar o erro global, resultando num elevado número de falsos negativos nas atividades críticas.

6.2. Implementação Robusta do SMOTE

Para combater este fenómeno, rejeitou-se a simples duplicação de registos (*oversampling*), que conduziria a *overfitting*. Optou-se pela implementação do algoritmo SMOTE (*Synthetic Minority Over-sampling Technique*).



Como podemos observar, as amostras sintéticas fabricadas, parecem corresponder às amostras originais, comprovando a funcionalidade da implementação do SMOTE.

Para além da visualização criada, para demonstração, foi também aplicado o SMOTE na *pipeline* de *deployment*, como forma de melhorar a classificação.

Nota de Implementação: É crucial salientar que o SMOTE foi aplicado de forma dinâmica e apenas ao conjunto de treino dentro da validação cruzada. Se o SMOTE fosse aplicado ao *dataset* completo antes da divisão, haveria "fuga de informação" (*data leakage*), pois amostras sintéticas no teste seriam interpolações de amostras originais do treino. A nossa abordagem garantiu a integridade da validação, permitindo ao modelo aprender a topologia das classes minoritárias sem adulterar as métricas de teste.

7. Análise de *Features* e Estratégias de Validação

7.1. *Handcrafted Features* vs. *Embeddings*

Comparou-se a eficácia das características estatísticas manuais (174 *features*) contra *Embeddings* (512 dimensões) extraídos de redes neurais pré-treinadas.

Análise Crítica: Contrariamente à tendência atual de *Deep Learning*, as *handcrafted features* apresentaram um desempenho superior.

- Justificação: Os *embeddings* genéricos de *transfer learning* procuram padrões universais que podem não estar alinhados com a especificidade biomecânica deste *dataset*. As *handcrafted features* (médias, desvios padrões, correlações entre eixos) possuem um significado físico direto, descrevendo a intensidade e periodicidade do movimento, tornando-as mais discriminantes para este domínio específico.

7.2. *Within-Subject* vs. *Between-Subject*

A discrepância observada entre os resultados *Within-Subject* (~83% *accuracy*) e *Between-Subject* (~61% *accuracy*) é o ponto fulcral da discussão sobre a viabilidade do sistema.

- Interpretação: O modelo *Within-Subject* aprende não só a atividade, mas também a maneira de agir e pequenos detalhes biofísicos do movimento do participante (a cadência específica da passada, a postura ao sentar).
- Quando testado em modo *Between-Subject* (participantes nunca vistos), o modelo falha porque essa “assinatura pessoal” não está presente. Isto demonstra que, sem uma fase de calibração, o sistema tem dificuldade em generalizar a cinemática do movimento para indivíduos com biomecânicas distintas (altura, peso, amplitude de movimento).

8. Classificação e Discussão dos Resultados

8.1. Síntese de Resultados Quantitativos

Apresentam-se abaixo os resultados obtidos após a otimização dos hiperparâmetros (procura do melhor k) para as 12 configurações testadas. Os valores de F1-Score e Accuracy representam a média e o desvio padrão (σ) obtidos através de validação cruzada.

Tabela 1: Resultados para Handcrafted Features (174 dimensões)

Cenário	Split Strategy	Melhor k	F1-Score ($\pm\sigma$)	Accuracy ($\pm\sigma$)	Atividade Crítica (Recall)
All Features	Within	1	0.8153 (± 0.0027)	0.8342 (± 0.0034)	Ativ. 7 (0.530)
	Between	13	0.5883 (± 0.0210)	0.6164 (± 0.0187)	Ativ. 5 (0.482)
PCA	Within	1	0.7678 (± 0.0050)	0.7866 (± 0.0043)	Ativ. 7 (0.477)
	Between	13	0.5662 (± 0.0262)	0.5969 (± 0.0270)	Ativ. 7 (0.473)
ReliefF	Within	1	0.7293 (± 0.0206)	0.7473 (± 0.0209)	Ativ. 7 (0.428)
	Between	13	0.5084 (± 0.0291)	0.5410 (± 0.0239)	Ativ. 7 (0.409)

Tabela 2: Resultados para Embeddings (512 dimensões)

Cenário	Split Strategy	Melhor k	F1-Score ($\pm\sigma$)	Accuracy ($\pm\sigma$)	Atividade Crítica (Recall)
All Embeddings	Within	2	0.6767 (± 0.0063)	0.7078 (± 0.0061)	Ativ. 7 (0.430)
	Between	2	0.4489 (± 0.0096)	0.4806 (± 0.0111)	Ativ. 7 (0.355)
PCA	Within	13	0.5834 (± 0.0045)	0.6157 (± 0.0046)	Ativ. 7 (0.354)
	Between	11	0.4050 (± 0.0159)	0.4386 (± 0.0230)	Ativ. 7 (0.288)
ReliefF	Within	12	0.5502 (± 0.0129)	0.5967 (± 0.0128)	Ativ. 7 (0.318)
	Between	12	0.3983 (± 0.0149)	0.4560 (± 0.0129)	Ativ. 3 (0.085)

A observação das tabelas confirma a superioridade do cenário *Features All / Within-Subject* sobre todas as outras combinações. Destaca-se também que a Atividade 7 (*Upstairs & Talking*) é consistentemente a classe mais difícil de classificar (menor *Recall*) na grande maioria dos modelos, o que é expectável, uma vez que era a atividade com menos amostras originais.

8.2. Otimização do k-NN

O classificador k-NN foi implementado de raiz, introduzindo melhorias face à versão base:

1. Votação Ponderada: Implementou-se o peso pelo inverso da distância ($1/d$). Isto penaliza vizinhos distantes, reduzindo o ruído nas fronteiras de decisão incertas.

2. Métrica da Distância: Testes comparativos entre Manhattan e Euclidiana revelaram a superioridade da distância Manhattan. Isto indica que, para este espaço de características de alta dimensão, a soma das diferenças absolutas é uma métrica mais robusta do que a distância geométrica direta, sendo menos sensível a valores extremos em *features* individuais.


8.3. Limitações Físicas: O Problema da Fala

A análise das matrizes de confusão expôs a maior fragilidade do sistema: a incapacidade de distinguir consistentemente atividades "com fala" das suas variantes "sem fala" (ex: *Walking* vs. *Walking & Talking*). Chega-se assim à conclusão – o problema não é algorítmico, mas sim físico.


1. Atenuação Mecânica: As vibrações das cordas vocais dissipam-se através dos tecidos moles e esqueleto antes de atingirem os sensores (cintura/tornozelo).

2. Limitação de Nyquist: A frequência fundamental da voz humana situa-se tipicamente entre 85Hz e 255Hz. Uma vez que os acelerómetros em contextos de HAR operam frequentemente a taxas de amostragem baixas (ex: 50Hz), o sinal de voz sofre *aliasing* ou é filtrado como ruído de alta frequência, tornando impossível a sua recuperação e distinção do ruído de impacto do movimento.

Matriz de Confusão Média - FEATURES_ALL (BETWEEN-Subject)
k=13 | Accuracy=0.6164 | F1-Score=0.5883



Matriz de Confusão Média - FEATURES_ALL (WITHIN-Subject)
k=1 | Accuracy=0.8342 | F1-Score=0.8153



8.4. Tentativas Experimentais Falhadas

Na tentativa de contornar estas limitações, exploraram-se duas abordagens extra:


1. Classificador Hierárquico (2 Estágios): Um classificador para o movimento base e outro para a fala. O segundo estágio teve uma performance próxima do aleatório, confirmando a ausência de sinal discriminante.

2. Features de Frequência: Tentou-se isolar bandas de frequência específicas via FFT. No entanto, devido à baixa taxa de amostragem referida acima, estas *features* captaram apenas ruído, não contribuindo para a separação das classes.

9. Deployment e Contexto de Aplicação

9.1. Seleção do Modelo e Justificação Estatística

Para a fase de *deployment*, selecionou-se o modelo *Within-Subject* com *Features Handcrafted* ($k=1$). Esta decisão não foi arbitrária, mas fundamentada nos resultados dos testes de hipótese (Teste de *Wilcoxon*), onde esta configuração demonstrou ser estatisticamente superior às restantes, apresentando um F1-Score consistentemente elevado e uma baixa variância entre as iterações de teste.



Gráficos dos testes de hipótese da abordagem *Within-Subject*

9.2. Discussão do Contexto Real

A validade da escolha do modelo *Within-Subject* depende inteiramente do caso de uso que se pretende endereçar. Identificaram-se dois contextos distintos:

- Dispositivo Pessoal (O Cenário Escolhido): O sistema opera como um *smartwatch* ou telemóvel pessoal. O dispositivo aprende com o próprio utilizador ao longo do tempo. Neste cenário, o modelo *Within-Subject* é a representação correta da realidade, pois o sistema terá acesso a dados históricos do operador. O uso de $k=1$ é aceitável e eficaz porque, existindo dados suficientes do próprio utilizador, a amostra histórica mais próxima é, estatisticamente, a correta (alta consistência intra-pessoal).
- Monitorização Clínica Genérica: Para um sistema *plug-and-play* aplicado a novos utilizadores sem qualquer acesso prévio aos mesmos, seria obrigatório utilizar o modelo *Between-Subject* (apesar da *accuracy* inferior), uma vez que apenas essa estratégia garantiria uma robustez verdadeira na generalização para operadores desconhecidos.

Ao optarmos pelo Contexto A para a demonstração final, validámos que a pipeline de processamento e classificação é altamente fiável quando o sistema é personalizado, cumprindo os objetivos de robustez técnica propostos no projeto.

9.3. Simulação da Pipeline de Produção

Para comprovar a eficácia do modelo no "Contexto A", desenvolveu-se um script de simulação (*deployment.py*) que replica o ciclo de vida de uma previsão em tempo real. A robustez deste teste assenta em dois pilares técnicos: a perturbação do input e a estratégia de treino.

9.3.1. Seleção e Perturbação do Input

Em vez de alimentar o modelo com dados "limpos" diretamente do dataset, o sistema seleciona aleatoriamente um segmento de atividade e aplica-lhe transformações antes da classificação:

- Injeção de Ruído: Adiciona-se ruído gaussiano aleatório aos sinais brutos dos sensores.
- Scaling Aleatório: Aplica-se um fator de escala (multiplicação por um escalar próximo de 1.0) à amplitude do sinal.

Justificação: Estas perturbações simulam a variabilidade natural encontrada em sensores (ruído térmico, erros de calibração) e pequenas variações na intensidade do movimento humano. Se o modelo classificar corretamente mesmo

com este "ruído", prova-se que aprendeu padrões robustos e não apenas memorizou valores exatos.

9.3.2. Estratégia de Treino e Inferência

No momento da inferência, o modelo é re-treinado com todo o *dataset* disponível, com exceção apenas da amostra específica que está a ser testada (para evitar *data leakage*). Uma vez que a validação e a otimização do hiperparametro k foram concluídas com sucesso no exercício 5.3, podemos usar a totalidade do *dataset* para treino, prescindindo de divisões de validação para maximizar a base de conhecimento disponível para a classificação.

Esta abordagem materializa tecnicamente o "Contexto A": ao incluirmos os dados do participante alvo no conjunto de treino, estamos a simular a "memória" de um dispositivo pessoal. O fluxo de execução final é o seguinte:

1. **Ingestão:** Receção do *array* (256, 9) com ruído injetado.
2. **Extração:** Cálculo das 185 *handcrafted features* (Estatísticas e Correlações).
3. **Normalização:** Aplicação do *StandardScaler* (ajustado aos dados de treino globais).
4. **Inferência:** O classificador k-NN ($k=1$) compara o vetor de entrada com a base de conhecimento completa e devolve a previsão.

Na simulação final (1000 iterações), esta arquitetura atingiu uma *accuracy* de 93%, confirmando a viabilidade do sistema para *deployment* em dispositivos pessoais.

10. Conclusão Final

A realização da Meta 2 permitiu consolidar a transformação de uma análise exploratória de dados num sistema de decisão inteligente e operacional. O projeto cobriu o ciclo de vida completo de uma solução de *Machine Learning*, desde o pré-processamento de sinais brutos até à simulação de um *deployment* em tempo real.

Os resultados obtidos permitem retirar três ilações fundamentais que transcendem o código implementado:

- Domínio vs. Complexidade: Ficou demonstrado que a complexidade algorítmica não é sinónimo de melhor desempenho. As *handcrafted features*, fundamentadas na física do movimento (energia, estatística descritiva), superaram consistentemente os *Embeddings* gerados por *Deep Learning*. Isto

valida a premissa de que, em domínios específicos como HAR, a interpretabilidade e o alinhamento das *features* com a natureza biomecânica do problema são mais valiosos do que representações latentes genéricas.

- Rigor Metodológico: O sucesso do modelo final dependeu estritamente do tratamento correto dos dados. A implementação de estratégias de validação cruzada diferenciadas (*Within* vs *Between*) expôs a fronteira entre a "memorização" de um utilizador e a "generalização" para a população. Adicionalmente, a aplicação de SMOTE com prevenção de *data leakage* (aplicado apenas ao treino) provou ser a chave para equilibrar a sensibilidade do classificador face a atividades minoritárias.
- Complexidade da Discriminação de Classes Sobrepostas: A dificuldade em distinguir consistentemente entre atividades com e sem fala (ex: *Walking* vs *Walking & Talking*) ilustrou um desafio clássico de reconhecimento de padrões: a sobreposição de assinaturas cinemáticas. Uma vez que o movimento corporal domina a amplitude do sinal registado pelos sensores inerciais, a componente vibratória da fala torna-se estatisticamente subtil. Este resultado destaca a complexidade de separar atividades cuja diferença fenotípica reside numa dimensão (vibração acústica) que é secundária face à magnitude do movimento físico principal.

Em suma, o protótipo final, validado com 93% de *accuracy* na simulação de *deployment*, provou ser uma solução robusta para cenários de dispositivos personalizados. O projeto encerra-se com uma *pipeline* validada estatisticamente, consciente das suas fronteiras operacionais e pronta para aplicação em contexto real.